

ML-SUPERB & JEPA

Trois slides pour le rapport principal (`report.tex`)

Janis Vadim Bruny

3 avril 2026

- Protocole **ML-SUPERB** : encodeur SSL **gelé**, petite tête **CTC**, budgets **10 min / 1 h** par langue.
- Question centrale : comparer des représentations **JEPA** / **WavJEPA** à **HuBERT** sous la **même** recette downstream.
- Résultats ASR : on rapporte **CER** et **WER** après décodage et scoring MLSUPERB — **tableau agrégé** sur la slide suivante, détail par langue dans `report.tex`.
- Multilingue : mélange eng / deu / fra ; conditions comparées : **ASR seul** (10 min et 1 h), **ASR+LID** (10 min), **LoRA** sur ASR seul (10 min).

Représentations et benchmarks (mono, multilingue, ABX)

ABX mesure la séparabilité phonétique dans le latent ; CER/WER mesurent l'alignement texte.

Multilingue & adaptation

Réglage	CER	WER
ASR-only 10 min	24.96	23.48
ASR-only 1 h	20.76	18.30
ASR+LID 10 min	26.33	25.49
LoRA ASR-only 10 min	24.95	23.66

- LoRA : pas de gain
- 10 min $\rightarrow$ 1 h : grand écart

ABX

Modèle	err. ABX
HuBERT	0.5216
WavJEPa HF	0.5895
$\Delta (W - H)$	+0.0679

- HuBERT mieux sur ABX.
- Δ ABX positif : HuBERT devant.

Temps de training

Piste	L4 (h)
Multi. ASR 10 min	5.93
Multi. ASR 1 h	11.22
LID-only 10 min	4.93
LID-only 1 h	11.17
WavJEPA ASR eng1 HF	1.99
WavJEPA ASR eng1 local	1.62

Conclusion : la perte SSL peut baisser sans aligner le CER/WER ; espace latent et géométrie CTC peuvent **tourner** tout en gardant des scores ASR proches en bas budget.

Dérive des poids

- Cosinus moyen (HF / local) $\approx -0,008$; ratio normes local/HF $\approx 1,59$.
- Lignes ctc_lo : cosinus moyen $\approx 0,032$ entre runs HF et local.